



Tecnológico de Monterrey

Proyecto | lectura, escritura, archivos de Big Data PySpark

Integrantes

Salma Alejandra Macías Rosas A01620186

Marcelo Ismael López Verdugo A00959089

Dario Maximiliano Mendoza Orozco A01361220

Diana Jimena López Nájera A01024913

Fecha

05 de mayo del 2026

Nombre de la Materia

Análisis de grandes volúmenes de datos

Profesor

Dr. Iván Olmos Pineda

Tema de interés

“Comportamiento de usuarios en comercio electrónico.”

El objetivo general es analizar patrones de comportamiento y navegación de los usuarios mediante el procesamiento a gran escala de eventos de interacción (Big Data), con el fin de identificar los factores que influyen en la conversión de compra en una tienda en línea multi-categoría. Para trabajar este tema se seleccionó el dataset “*eCommerce behavior data from multi category store*”, disponible en Kaggle, el cual contiene registros de eventos generados por usuarios en una tienda en línea multi-categoría. Cada registro representa una acción realizada por un usuario, como visualizar un producto, agregar al carrito o comprarlo, incluyendo información del producto, categoría, marca, precio, usuario y sesión. E

Dataset

El dataset se puede consultar en la siguiente liga: <https://www.kaggle.com/datasets/mkechinov/ecommerce-behavior-data-from-multi-category-store>.

Fue publicado en Kaggle por Michael Kechinov. Este conjunto de datos tiene un tamaño mayor a 1 GB, se encuentra disponible en formato CSV y contiene registros suficientemente detallados para realizar análisis con herramientas de Big Data como PySpark

Dicho dataset resulta conveniente para trabajar durante el curso porque está dividido en archivos mensuales, en este caso estaremos analizando el de octubre, lo que permite analizarlo de forma progresiva o completa según los recursos computacionales disponibles. Su estructura facilita la identificación de estadísticas generales, valores faltantes, tipos de datos y posibles problemas de calidad desde las primeras etapas del análisis.

Ejecución de descarga del dataset:

```
import kagglehub
from kagglehub import KaggleDatasetAdapter

# Set the path to the file you'd like to load
# This dataset contains monthly CSV files (e.g., 2019-Oct.csv, 2019-Nov.csv, etc.)
# Specify the file you want to load
file_path = "2019-Oct.csv" # Change this to the desired file

try:
    # Load the latest version
    df = kagglehub.load_dataset(
        kagglehub.dataset_id("mkechinov/e-commerce-behavior-data-from-multi-category-store"),
        file_path,
        # Provide any additional arguments like
        # sql_query or pandas_kwargs. See the
        # documentation for more information:
        # https://github.com/Kaggle/kagglehub/blob/main/README.md#kaggledatasetadapters
    )

    print("Dataset shape:", df.shape)
    print("First 5 records:")
    print(df.head())
    print("Column names:")
    print(df.columns.tolist())
except FileNotFoundError:
    print("File not found. Available files in the dataset might include:")
    print("2019-Oct.csv, 2019-Nov.csv, 2019-Dec.csv, 2020-Jan.csv, etc.")
    print("Please update the file_path variable with a valid filename.")
except Exception as e:
    print("Error loading dataset: (e)")
```

3. Revisión del dataset:

Columna	Tipo de dato	Descripción	Valores faltantes
event_time	timestamp / string	Fecha y hora del evento (UTC)	No

event_type	string	Tipo de evento (view, cart, purchase, etc.)	No
product_id	int64	ID del producto	No
category_id	int64	ID de categoría	No
category_code	string	Categoría jerárquica	Sí (frecuente 20-40%)
brand	string	Marca del producto	Sí (frecuente 20-40%)
price	float64	Precio del producto	No
user_id	int64	ID del usuario	No
user_session	string	ID de sesión	Puede faltar(<1%)

Sesión pyspark

Spark

4.1.1

Jobs

Stages

Storage

Environment

Executors

SQL / DataFrame

ExploracionDatos application l

Spark Jobs (?)

User: MLOPE243

Started At: 2026/05/05 19:33:02

Total Uptime: 26 min

Scheduling Mode: FIFO

Completed Jobs: 34

Event Timeline

Completed Jobs (34)

Page: 1

1 Pages. Jump to 1. Show 100 items in a page. Go

Job Id	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
33	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:57:48	0.1 s	1/1 (1 skipped)	1/1 (43 skipped)
32	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:57:31	17 s	1/1	43/43
31	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:57:31	0.4 s	1/1 (1 skipped)	1/1 (43 skipped)
30	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:57:10	21 s	1/1	43/43
29	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:57:10	85 ms	1/1 (1 skipped)	1/1 (43 skipped)
28	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:56:55	15 s	1/1	43/43
27	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:56:54	74 ms	1/1 (1 skipped)	1/1 (43 skipped)
26	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:56:42	12 s	1/1	43/43
25	SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768 SanonfunSwiithThreadLocalCaptured\$2 at CompletableFuture.java:1768	2026/05/05 19:56:42	88 ms	1/1 (1 skipped)	1/1 (43 skipped)

4. Análisis:

Nombre y origen del dataset

El dataset se llama “eCommerce behavior data from multi category store” Este archivo contiene datos de comportamiento de octubre de 2019 de una gran tienda online multicategoría.Cada fila del archivo representa un evento. Todos los eventos están

relacionados con productos y usuarios. Cada evento se asemeja a una relación de muchos a muchos entre productos y usuarios.

Descripción general de su contenido

El dataset seleccionado permite analizar el comportamiento de usuarios dentro de una tienda en línea a partir de diferentes tipos de eventos. Estos eventos pueden representar acciones como visualizar productos, agregarlos al carrito, eliminarlos del carrito o comprarlos. Esta estructura permite estudiar el proceso de conversión de los usuarios desde la exploración inicial hasta la compra final.

De acuerdo con la información del repositorio de Kaggle, el dataset completo contiene aproximadamente 285 millones de eventos de usuarios provenientes de una tienda e-commerce multi-categoría. Además, el repositorio reporta que los archivos están en formato CSV y tienen un tamaño aproximado de 5 GB, por lo que cumplen con el requisito de trabajar con datos superiores a 1 GB.

A partir de la exploración inicial del dataset, se pueden identificar varias líneas de análisis. Primero, el conteo por *event_type* permitirá observar qué acciones son más frecuentes dentro de la plataforma. Es esperable que las visualizaciones de productos sean mucho más comunes que las compras, lo cual puede indicar un desbalance natural en el comportamiento de navegación de los usuarios. Este punto es importante porque, si más adelante se construye un modelo predictivo de compra, será necesario considerar ese desbalance.

También se pueden analizar las categorías, marcas y productos con mayor interacción. Por ejemplo, las variables *category_code*, *brand* y *product_id* permiten identificar qué tipos de productos concentran más visualizaciones, carritos o compras. Esto puede apoyar decisiones relacionadas con marketing, inventario, recomendaciones o estrategias de promoción.

Otra variable importante es *price*, ya que permite estudiar la relación entre el precio de los productos y el comportamiento del usuario. Por ejemplo, se podría analizar si los productos de menor precio tienen una mayor frecuencia de compra o si ciertos rangos de precio generan más visualizaciones pero menor conversión.

Durante la revisión inicial también es necesario observar posibles problemas de calidad de datos, ya que existen valores faltantes en columnas como *brand*, *category_code* o *user_session*, ya que algunos productos podrían no tener una marca registrada o una categoría completamente definida. Estos valores faltantes deberán identificarse antes de realizar análisis más avanzados.

En conclusión, el dataset contiene información relevante para el tema de investigación porque permite estudiar el comportamiento de usuarios en una tienda en línea a gran escala. Su volumen, estructura tabular y variedad de variables lo hacen adecuado para aplicar técnicas de Big Data con PySpark y desarrollar análisis posteriores sobre conversión de compra, comportamiento por sesión, productos más relevantes y patrones de interacción.