



Análisis de Grandes Volúmenes de Datos

POSGRADOS

Algoritmos de Aprendizaje

Agenda



1. Construcción de modelos de aprendizaje
2. Construcción del conjuntos train y test
3. Construcción de modelos con PySpark

Construcción de modelos de aprendizaje



Algoritmos de aprendizaje

- Existen diferentes tipos de aprendizaje máquina
 - Aprendizaje supervisado
 - Aprendizaje no supervisado
 - Aprendizaje por refuerzo
- Extensiones
 - Aprendizaje profundo
 - Aprendizaje en grandes volúmenes de datos (big data)*

Aprendizaje en grandes volúmenes de datos

- Ventajas
 - En general, se tiene una suficiente cantidad de instancias o muestras para construir modelos de calidad (siempre y cuando la muestra sea representativa del dominio)
- Retos
 - Es muchos casos, es inviable generar una gran cantidad de experimentos para encontrar los mejores modelos (búsqueda de parámetros, validación cruzada)
 - Es importante garantizar la calidad de los datos a usar (muestra representativa)
 - Selección cuidadosa de los hiper – parámetros de ajuste del algoritmo
 - Selección adecuada de métricas para medir la calidad de los resultados

Construcción de conjuntos train y test



Muestreo

- La construcción de conjuntos train y test es crucial en el Big Data
 - La muestra inicial debe ser de calidad (muestra representativa)
 - El particionamiento a generar para la construcción del train y test, debe igualmente garantizar que las particiones sean representativas
 - Se debe cuidar que la cantidad de instancias por partición sean las necesarias y suficientes
- Para lograrlo, se deben de emplear técnicas de muestreo
 - Probabilísticas *
 - No probabilísticas

Muestreo probabilístico

- Existen diferentes tipos de muestreo
 - Muestreo aleatorio simple
 - Muestreo estratificado
 - Muestreo por grupos (una etapa, dos etapas)
 - Muestreo sistemático
 - Muestreo multietapa

Construcción de modelos con PySpark



Generalidad

- Para la construcción de modelos de aprendizaje con PySpark se debe tomar en cuenta lo siguiente
 - PySpark implementa diversos algoritmos de aprendizaje (supervisado, no supervisado, regresión)
 - El ajuste de los hiper – parámetros es crítica, ya que en general, cada experimento lanzada es computacionalmente caro
 - Se debe elegir adecuadamente las métricas para medir la calidad de los modelos

Conclusiones



Conclusiones Generales

- Aplicar técnicas de muestreo es crucial para la construcción de modelos de calidad
- Las técnicas de muestreo son aplicables desde la construcción de la muestra hasta la construcción de los conjuntos train - test
- Otros aspectos clave para construir modelos de calidad es el ajuste de hiper – parámetros, así como la selección de las técnicas correctas para medir la calidad del resultado



D.R. © Tecnológico de Monterrey, México, 2024.
Prohibida la reproducción total o parcial
de esta obra sin expresa autorización del
Tecnológico de Monterrey.