



Tecnológico de Monterrey

Proyecto | Base de Datos de Big Data

Integrantes

Salma Alejandra Macías Rosas A01620186

Marcelo Ismael López Verdugo A00959089

Dario Maximiliano Mendoza Orozco A01361220

Diana Jimena López Nájera A01024913

Fecha

12 de mayo del 2026

Nombre de la Materia

Análisis de grandes volúmenes de datos

Profesor

Dr. Iván Olmos Pineda

Caracterización de la población

La población objetivo P de esta investigación está conformada por los eventos de comportamiento de usuarios registrados durante octubre de 2019 en una tienda en línea multi-categoría. Cada registro representa una interacción entre un usuario y un producto, como visualizar un artículo, agregarlo al carrito o realizar una compra. De acuerdo con la primera entrega del proyecto, el objetivo general es analizar patrones de comportamiento y navegación para identificar factores que influyen en la conversión de compra dentro de un entorno de comercio electrónico. Además, el dataset contiene información del producto, categoría, marca, precio, usuario y sesión, lo que permite caracterizar el comportamiento desde diferentes perspectivas.

Para construir una muestra representativa M, es necesario identificar variables que describen los comportamientos habituales de esta población. En este caso, las variables más relevantes son aquellas que permiten entender qué acción realizó el usuario, cuándo ocurrió la interacción, qué tipo de producto estuvo involucrado, cuál fue su precio, a qué marca pertenece y cómo se relacionan los eventos dentro de una sesión de navegación.

Nombre de la variable	Dominio de la variable	Descripción estadística conocida de la variable	Comentarios adicionales
event_type	Variable categórica. Valores observados: view, cart y purchase.	Distribución obtenida con PySpark: view = 40,779,399 registros (96.07%); cart = 926,516 registros (2.18%); purchase = 742,849 registros (1.75%). No presenta valores faltantes.	Variable principal para describir la acción del usuario. Permite analizar el embudo de conversión: visualización -> carrito -> compra. Existe un fuerte desbalance, ya que la mayoría de eventos son visualizaciones.
event_time	Marca temporal de fecha y hora. Para este análisis corresponde a eventos registrados durante octubre de 2019.	No presenta valores faltantes. El tipo de dato identificado en PySpark es timestamp.	Permite analizar patrones temporales. Puede transformarse en día del mes, día de la semana, hora o periodo del día para identificar horarios de mayor actividad.
product_id	Identificadores únicos de producto. Dominio numérico entero, pero debe interpretarse como identificador.	Tiene 166,794 valores únicos y no presenta valores faltantes.	Sirve para identificar productos con mayor interacción o conversión. No conviene usarla como variable principal de particionamiento por su alta cardinalidad.
category_id	Identificadores únicos de categoría. Dominio numérico, pero debe interpretarse como identificador.	Tiene 624 valores únicos y no presenta valores faltantes.	Puede complementar a category_code, aunque es menos interpretable porque representa la categoría mediante un identificador numérico.

category_code	Categorías jerárquicas del producto o valor nulo. Ejemplos: electronics.smartphone, electronics.clocks, computers.notebook.	Tiene 127 valores únicos. Presenta 13,515,609 valores faltantes, equivalentes al 31.84% del dataset. La categoría más frecuente es electronics.smartphone, con 11,507,231 registros (27.11%).	Ayuda a estudiar el comportamiento por tipo de producto. Debido a sus valores faltantes, se recomienda tratarlos como unknown o analizarlos por separado. Para particionar, puede transformarse en categoría principal.
brand	Marcas de productos o valor nulo. Ejemplos frecuentes: samsung, apple, xiaomi, huawei.	Tiene 3,446 valores únicos. Presenta 6,113,008 valores faltantes, equivalentes al 14.40%. Marcas más frecuentes: samsung = 5,282,775 (12.45%), apple = 4,122,554 (9.71%) y xiaomi = 3,083,763 (7.26%).	Permite analizar preferencias o concentración de interacción por marca. Puede generar muchas categorías, por lo que se recomienda usarla con cuidado en particionamiento.
price	Variable numérica continua. Valores válidos esperados: mayores o iguales a 0.	Conteo: 42,448,764. Media: 290.32; desviación estándar: 358.27; mínimo: 0.00; máximo: 2574.07; percentil 25: 64.78; mediana: 161.83; percentil 75: 357.77. No presenta valores faltantes.	Permite evaluar si el precio influye en el comportamiento de navegación y compra. Puede transformarse en rangos de precio bajo, medio y alto para el particionamiento.
user_id	Identificadores únicos de usuario. Dominio numérico entero, pero debe interpretarse como identificador.	Tiene 3,022,290 valores únicos y no presenta valores faltantes.	Permite analizar usuarios únicos, recurrencia e intensidad de interacción. No conviene usarla como variable principal de particionamiento por su alta cardinalidad.
user_session	Identificadores únicos de sesión o valor nulo.	Tiene 9,244,422 valores únicos. Presenta 2 valores faltantes, equivalentes aproximadamente al 0.000005% del dataset.	Permite estudiar secuencias de navegación dentro de una sesión, por ejemplo view -> cart -> purchase. Es útil para análisis de comportamiento, pero no como partición principal.

Nota: las estadísticas fueron calculadas con PySpark sobre el archivo de octubre de 2019. La población analizada contiene 42,448,764 registros y 9 columnas.

A partir de estas variables, se puede comprender mejor el comportamiento habitual de la población objetivo. La variable `event_type` permite identificar las acciones principales de los usuarios; `event_time` ayuda a analizar el comportamiento en función del tiempo; `category_code`, `brand` y `product_id` permiten estudiar la interacción con los productos; `price` permite evaluar la influencia del costo en la decisión de compra; y `user_id` junto con `user_session` permiten observar patrones de navegación a nivel usuario y sesión.

Para las siguientes etapas del proyecto, no todas estas variables serán utilizadas directamente para particionar la base de datos, ya que algunas tienen demasiados valores únicos, como `product_id`, `user_id` y `user_session`. Sin embargo, sí son importantes para caracterizar la población y conservar información relevante dentro de cada subconjunto de datos.

Particionamiento

La implementación técnica del proceso de particionamiento, desarrollada mediante la librería PySpark, se encuentra disponible para su consulta y ejecución en el siguiente enlace: https://drive.google.com/file/d/199gBymkgdi5-wYrZWjXNDu_5GHvTBsTp/view?usp=sharing

En esta etapa se diseñó el proceso de particionamiento para la base de datos D. El objetivo es dividir los registros en subconjuntos definidos por reglas claras, de forma que cada partición represente un tipo específico de interacción dentro de la tienda en línea.

Para evitar repetir la caracterización general de la población, en este apartado el enfoque se centra en cómo transformar las variables seleccionadas y cómo calcular el peso de cada combinación dentro del conjunto de datos. La base analizada contiene 42,448,764 registros y 9 columnas. A partir de ella se generaron variables derivadas que permiten crear particiones interpretables y útiles para una futura construcción de muestra representativa.

Las variables elegidas para el particionamiento fueron `event_type`, `category_group`, `price_range` y `time_period`. Estas variables permiten diferenciar los eventos por acción del usuario, categoría general del producto, nivel de precio y momento del día. La selección evita usar identificadores con demasiados valores únicos, como `product_id`, `user_id` y `user_session`, ya que estos podrían producir una cantidad excesiva de particiones muy pequeñas.

Variables utilizadas para el particionamiento

Variable original	Variable de particionamiento	Regla de transformación	Justificación
<code>event_type</code>	<code>event_type</code>	Se conserva el valor original: <code>view</code> , <code>cart</code> o <code>purchase</code> .	Distingue la acción del usuario dentro del embudo de conversión.
<code>category_code</code>	<code>category_group</code>	Se toma la categoría principal antes del primer punto. Los valores nulos se clasifican como <code>unknown</code> .	Agrupar productos en categorías generales y evita particiones demasiado específicas.
<code>price</code>	<code>price_range</code>	Se clasifica en <code>low</code> , <code>medium</code> y <code>high</code> usando percentiles de precio.	Permite comparar el comportamiento según nivel de precio.
<code>event_time</code>	<code>time_period</code>	Se extrae la hora del evento y se agrupa en periodos del día.	Permite analizar diferencias según el horario de interacción.

La variable `category_group` se generó a partir de `category_code`. Por ejemplo, valores como `electronics.smartphone` y `electronics.clocks` se agruparon en `electronics`. Los registros sin

categoría se conservaron bajo la etiqueta unknown, ya que representan una proporción importante del dataset y eliminarlos podría sesgar la muestra posterior.

La variable price_range se construyó con base en los percentiles del precio calculados previamente. Se definió low para precios menores o iguales a 64.78, medium para precios mayores a 64.78 y menores o iguales a 357.77, y high para precios mayores a 357.77. Finalmente, time_period agrupó los eventos en night, morning, afternoon y evening según la hora extraída de event_time.

Distribución de las variables de particionamiento

Antes de generar las combinaciones, se calculó la frecuencia individual de cada variable. Esto permite conocer el peso de cada dimensión dentro de la base D y sirve como referencia para interpretar las particiones combinadas.

event_type	Registros	Probabilidad	Porcentaje
view	40,779,399	0.9607	96.07%
cart	926,516	0.0218	2.18%
purchase	742,849	0.0175	1.75%

category_group	Registros	Probabilidad	Porcentaje
electronics	16,135,623	0.3801	38.01%
unknown	13,515,609	0.3184	31.84%
appliances	4,967,294	0.1170	11.70%
computers	2,324,217	0.0548	5.48%
apparel	1,542,924	0.0363	3.63%
furniture	1,247,160	0.0294	2.94%
auto	1,013,115	0.0239	2.39%
construction	730,834	0.0172	1.72%
kids	520,619	0.0123	1.23%
accessories	238,238	0.0056	0.56%

price_range	Registros	Probabilidad	Porcentaje
medium	21,234,978	0.5002	50.02%
high	10,700,699	0.2521	25.21%
low	10,513,087	0.2477	24.77%

time_period	Registros	Probabilidad	Porcentaje
morning	15,509,143	0.3654	36.54%
night	13,838,576	0.3260	32.60%
afternoon	7,262,203	0.1711	17.11%
evening	5,838,842	0.1376	13.76%

Los resultados muestran que la base está dominada por eventos de visualización, categorías relacionadas con electrónica, productos de precio medio y actividad concentrada principalmente en morning y night. Esta distribución debe considerarse al construir una muestra representativa, ya que no todos los grupos tienen el mismo peso dentro de la población.

Combinaciones de particionamiento y probabilidades de ocurrencia

El particionamiento final se obtuvo combinando las cuatro variables seleccionadas. Cada partición representa una regla específica que debe cumplir un registro para pertenecer a ese subconjunto.

La regla general utilizada fue: Partición = event_type + category_group + price_range + time_period.

La probabilidad de ocurrencia de cada combinación se calculó dividiendo el número de registros de la partición entre el número total de registros de D. En este caso, el total utilizado fue 42,448,764 registros.

Probabilidad de la partición = registros de la partición / registros totales de D

Partición	event_type	category_group	price_range	time_period	Registros	Probabilidad	Porcentaje
P1	view	electronics	medium	morning	2,989,195	0.0704	7.04%
P2	view	electronics	medium	night	2,603,616	0.0613	6.13%
P3	view	electronics	high	morning	2,145,518	0.0505	5.05%
P4	view	unknown	medium	morning	2,119,194	0.0499	4.99%
P5	view	unknown	low	morning	1,994,173	0.0470	4.70%
P6	view	electronics	high	night	1,875,934	0.0442	4.42%
P7	view	unknown	medium	night	1,831,648	0.0431	4.31%
P8	view	unknown	low	night	1,808,751	0.0426	4.26%
P9	view	electronics	medium	afternoon	1,291,889	0.0304	3.04%
P10	view	electronics	medium	evening	1,080,086	0.0254	2.54%
P11	view	electronics	high	afternoon	1,074,248	0.0253	2.53%
P12	view	unknown	medium	afternoon	1,025,477	0.0242	2.42%
P13	view	unknown	low	afternoon	1,014,086	0.0239	2.39%
P14	view	appliances	medium	morning	962,852	0.0227	2.27%
P15	view	appliances	medium	night	925,085	0.0218	2.18%

Las combinaciones con mayor presencia corresponden a eventos view. Esto era esperado porque la mayor parte de la población corresponde a visualizaciones de productos. Las particiones más frecuentes se concentran principalmente en electronics y unknown, en rangos de precio medium y high, y durante los periodos morning y night.

La presencia de unknown como una de las categorías con mayor peso no se debe interpretar como una categoría de producto real, sino como el grupo de registros donde category_code estaba vacío. Se conserva porque representa una parte relevante de la población y puede contener patrones útiles para el análisis posterior.

Documentación técnica del proceso

Elemento	Descripción
Base de datos D	Archivo de octubre de 2019 del dataset eCommerce behavior data from multi category store.
Unidad de análisis	Evento individual realizado por un usuario.
Variables de particionamiento	event_type, category_group, price_range y time_period.
Regla general	Agrupar los registros por la combinación de las cuatro variables seleccionadas.
Probabilidad de ocurrencia	Registros de la partición divididos entre 42,448,764 registros totales.

Tratamiento de nulos	Los valores nulos de category_code se clasificaron como unknown.
Variables conservadas	Se mantienen las variables originales para análisis posteriores: event_time, event_type, product_id, category_id, category_code, brand, price, user_id y user_session.

El proceso de particionamiento permitió organizar la base original en subconjuntos definidos por reglas medibles. Cada combinación representa una porción específica de la población y cuenta con una probabilidad de ocurrencia calculada a partir de los datos reales procesados con PySpark.

Este enfoque ayuda a evitar una selección de registros sin estructura, ya que permite reconocer qué grupos tienen mayor o menor presencia dentro de la base. En una etapa posterior, estas probabilidades podrán utilizarse para aplicar una técnica de muestreo que respete la distribución observada y contribuya a construir una muestra representativa M.

Técnica de muestreo a aplicar por partición

Una vez definidas las reglas de particionamiento, se propone utilizar una técnica de muestreo estratificado proporcional por partición. Esta técnica consiste en seleccionar registros de cada partición de acuerdo con la proporción que dicha partición representa dentro de la base de datos original D.

En este proyecto, cada partición está definida por la combinación de las variables event_type, category_group, price_range y time_period. Por lo tanto, cada grupo representa un tipo específico de comportamiento dentro de la tienda en línea, considerando la acción del usuario, la categoría general del producto, el rango de precio y el periodo del día en que ocurrió el evento.

La probabilidad de ocurrencia de cada partición se calculó mediante la siguiente fórmula:

Probabilidad de la partición = número de registros de la partición / número total de registros de D

A partir de esta probabilidad, la muestra final M deberá construirse tomando registros de cada partición de manera proporcional a su peso dentro de la población. Por ejemplo, si una partición representa el 7.04% de la base original, entonces esa partición deberá representar aproximadamente el 7.04% de la muestra final.

Esta técnica es adecuada porque permite reducir el riesgo de sesgo en la selección de instancias. El dataset presenta un fuerte desbalance en la variable event_type, ya que la mayoría de los eventos corresponden a visualizaciones de productos, mientras que los eventos de carrito y compra son mucho menos frecuentes. Si se utilizara un muestreo aleatorio simple, existe el riesgo de que la muestra quede dominada por eventos de tipo view y no represente adecuadamente comportamientos menos frecuentes, pero relevantes para el análisis de conversión.

El muestreo estratificado proporcional permite conservar la distribución observada en la población original, respetando la presencia relativa de cada combinación de particionamiento. De esta manera, la muestra resultante mantiene la diversidad de patrones presentes en el

dataset, incluyendo distintos tipos de evento, categorías de producto, rangos de precio y periodos del día.

Además, esta técnica facilita la construcción posterior de conjuntos de entrenamiento y prueba, ya que permite asegurar que ambos conjuntos mantengan una composición similar a la población original. Esto es especialmente importante si en etapas posteriores se desea aplicar aprendizaje automático para analizar o predecir comportamientos de compra.

En conclusión, el muestreo estratificado proporcional por partición es apropiado para este proyecto porque permite recuperar instancias de manera ordenada, controlada y representativa, evitando que las particiones con mayor volumen dominen completamente la muestra y asegurando que los distintos comportamientos de la población objetivo estén presentes en la muestra final.